

Ecole nationale des ingénieur de sousse & ecole nationale des ingénieur de carthage
faite au sein de l'entreprise IWAY

encadreur entreprise : Mr. Mouhamed Guermazi

*Estimation prédictive de la consommation en assurance
maladie à l'aide de l'intelligence artificielle*

Préparé par : ahmed rayen thabet
& mouhamad dhia eddine thabet

Date : 12 août 2025

Étude Bibliographique – Modélisation Prédictive de la Consommation en Assurance Maladie par Intelligence Artificielle

1. Introduction

La prévision de la consommation de soins médicaux est essentielle pour les assureurs maladie afin d'optimiser les coûts, maîtriser les risques et ajuster les stratégies tarifaires. Les facteurs déterminants incluent :

- **Données démographiques** (âge, sexe, localisation)
- **Historique médical** (maladies chroniques, hospitalisations passées)
- **Caractéristiques des contrats** (taux de remboursement, plafonds, exclusions)
- **Évolutions dans le tableau des prestations** (nouvelles prestations, taux modifiés, suppression de services)

Une bonne modélisation doit anticiper l'impact de ces modifications sur les comportements des assurés.

2. Approches Statistiques Traditionnelles

2.1 Généralisé Linear Models (GLM)

Modèles régressifs (Poisson, Binomial négatif) pour prévoir le nombre d'actes.

Atouts : grande interprétabilité, bonne intégration actuarielle.

Limites : performances réduites en présence de relations non-linéaires.

Référence : McCullagh & Nelder (1989).

2.2 Modèles de Séries Temporelles

Ex. : ARIMA, SARIMA pour capter tendances et saisonnalités (ex. évolutions mensuelles).

Limites : faible adaptabilité en cas de choc (comme un changement des prestations).

Référence : Box, Jenkins & Reinsel (2015).

3. Approches par Apprentissage Automatique

3.1 Méthodes par Arbres**

Random Forest, XGBoost, LightGBM, CatBoost : haute performance sur données hétérogènes ; importance des variables rendue explicite.

Référence : Chen & Guestrin (2016).

3.2 Réseaux de Neurones**

- **MLP** pour données tabulaires.
- **LSTM** pour séquences temporelles (ex. consommation mensuelle).

Avantages : modélisation de dépendances longue durée ; **Inconvénient** : complexité et faible transparence.

Référence : Hochreiter & Schmidhuber (1997).

3.3 Modèles Hybrides**

Combinaison GLM + ML (e.g., boosting) : compromis entre interprétabilité et performances.

4. Modélisation des Changements de Tableaux de Prestations

4.1 Prediction Contrefactuelle**

Techniques en causal inference (Propensity Score Matching, Causal Forest) pour estimer les conséquences de scénarios hypothétiques.

Référence : Athey & Imbens (2016).

4.2 Simulation de Scénarios**

"Et si...?" : ajuster les paramètres (ex. taux, inclusion/exclusion) puis prédire les résultats pour chaque scénario.

5. Préparation des Données & Éthique

- Anonymisation (RGPD, HIPAA)
- Nettoyage des données (valeurs aberrantes, données manquantes)
- Conformité réglementaire (RGPD pour l'UE)

Référence : Commission Européenne (2016).

6. Tentatives Similaires dans la Réalité

6.1 Prédiction des coûts individuels via CNN et LSTM :

Morid et al. (2020) ont utilisé les réclamations d'un assureur (2013–2016) transformées en séries temporelles multivariées (visites, coûts) sous forme d'image ; un CNN les a analysées pour améliorer la prédiction des coûts individuels [arXiv](#).

6.2 Coûts populationnels grâce au Deep Learning** :

Drewe-Boss et al. (2020) ont formé un réseau de neurones sur les réclamations d'1,4 million d'assurés allemands ; le modèle devançait la régression Ridge et les modèles classiques (Morbi-RSA) [arXiv](#).

6.3 Identification des assurés très coûteux (HiCC)** :

Maisog et al. ont appliqué un modèle ML à 48 millions de données de réclamations pour prédire les assurés à très haute dépense (> \$250 000), avec un AUC de 91,2 %—crucial pour cibler la gestion des soins [arXiv](#).

6.4 Prévision multi-service en Europe** :

Une étude MDPI a développé des modèles (régression élastique, forêts aléatoires, SVM) pour un échantillon européen (176 032 assurés) en intégrant plusieurs types de services pour une stratification des risques plus complète [MDPI](#).

6.5 Prédiction en assurance hors soins de santé** (ex. dommage électronique) :

La Tesseract Academy a créé un pipeline combinant lissage exponentiel, ARIMA, Prophet, et modèles personnalisés pour prévoir les réclamations sur appareils électroniques, illustrant l'adaptation possible à l'assurance santé [Tesseract Academy](#).

7. Lacunes et Opportunités

- Intégration plus fluide des changements réglementaires dans les modèles.
- Usage élargi de l'**explained AI** (SHAP, LIME) pour renforcer l'acceptabilité métier.
- Modèles adaptables en **temps réel** via **streaming** de données médicales.

8. Sources Clés

1. McCullagh & Nelder (1989) – *GLM*.
2. Chen & Guestrin (2016) – *XGBoost*.
3. Hochreiter & Schmidhuber (1997) – *LSTM*.
4. Athey & Imbens (2016) – *Causal Forests*.
5. Box, Jenkins & Reinsel (2015) – *Time Series*.
6. Commission Européenne (2016) – *RGPD*.
7. Morid et al. (2020) – CNN sur séries coûts santé.
8. Drewe-Boss et al. (2020) – Deep Neural Network coûts population.
9. Maisog et al. (2019) – Modèle HiCC.
10. Étude multi-service EU – stratification des risques.

11. Tesseract Academy – pipeline ML pour réclamations.